

Quanto custa ser mulher e ser negra no mercado de trabalho brasileiro?

Uma medida da desigualdade de renda por sexo e raça a partir dos microdados da PNAD Contínua, 3º trimestre de 2022

Base amostral: os resultados são ponderados pelo peso amostral da PNAD.



Régua da Renda



Auditor de Paridade

Questionamentos e objetivos

20% de gap

Mediana ponderada das diferenças individuais obtidas ao alterar apenas a variável sexo para as mesmas pessoas avaliadas, mantendo-se constantes todas as demais variáveis.

Fonte: PNAD – IBGE, 2022

?

O quanto a renda salarial varia conforme fatores de sexo e raça no Brasil?

!

E quanto dessa diferença permanece quando idade, escolaridade, localização e cargo ficam iguais?

- Descrever o panorama nacional de renda da população segundo sexo e raça, com base ponderada pelo peso amostral nos microdados da PNAD Contínua 2022 (dados ocupados, com renda declarada);
- Estimar, com regressão e aprendizado de máquina, à associação entre sexo, raça e renda, controlando escolaridade, idade e unidade da Federação renda é alvo contínuo (regressão) e foi modelada em log por sua cauda longa;
- Verificar se o padrão nacional se mantém quando a unidade da Federação é controlada no modelo, e discutir os reflexos do achado;
- Comparar 8 modelos candidatos por validação cruzada no treino (nunca no teste) e reportar todo gráfico e importância a partir do modelo campeão

A base

Microdados públicos da PNAD Contínua, baixados direto do FTP do IBGE

487.786

pessoas no arquivo original

28 colunas

77.161

fração aleatória de 20%

guardada para o estudo

40.062

pessoas de 16+ com renda
do trabalho

a população analisada (amostra
final)

18,7 mi

brasileiras e brasileiros
representados

soma dos pesos amostrais

Fonte: PNAD Contínua 2022 (IBGE);

Variáveis: sexo (V2007), raça/cor (V2010), idade (V2009), escolaridade (VD3004) e UF — códigos do IBGE traduzidos para texto;

Tratamento das variáveis: escolaridade é ordinal (existe ordem: fundamental < médio < superior); raça e UF são one-hot (não existe ordem entre categorias);

Critério do governo: peso amostral (V1028) — cada pessoa entrevistada representa milhares de brasileiros; toda média, mediana e proporção aqui é ponderada por esse peso, senão refletiria só a amostra, não o Brasil;

Alvo: VD4020, o rendimento efetivo de todos os trabalhos, em reais. Problema de regressão, o alvo foi modelado em log e a mediana foi usada como medida central;

Amostra: Amostra sistemática de 5%: 74.311 registros × 22 colunas → 31.483, de 16 anos ou mais, com rendimento declarado;

Treino e teste: 30.046 e 10.016 pessoas, divididos de forma estratificada por faixa de renda;

Limitações: A PNAD registra sexo binário, sem identidade de gênero nem orientação sexual.

Hipóteses

H1

Mulheres têm renda de trabalho menor que homens

Mediana R\$ 1.500 contra R\$ 1.800. Mann-Whitney $p = 2,75e-74$

H2

Pessoas pretas e pardas têm renda menor que brancas

25,0% abaixo na mediana. Kruskal-Wallis $p = 0,0$

H3

Mais escolaridade, mais renda

Spearman 0,456. Superior completo: +125% sobre o médio

H4

Desigualdade persiste dentro de níveis iguais de escolaridade

Mediana feminina menor em 7 de 7 níveis

H5

Gênero e raça se somam

Homem branco R\$ 2.300 contra mulher negra R\$ 1.220

H6

Parte da diferença vem da jornada, mas não toda

Jornada 10,3% menor, renda por hora ainda 10,0% menor

Dois conjuntos de variáveis



Quem a pessoa é

9 variáveis

idade, escolaridade, anos de estudo, pessoas no domicílio, sexo, raça ou cor, UF, situação do domicílio, tipo de área

Mede o GAP TOTAL: quanto a renda varia com sexo e raça no mercado como um todo.



Quem ela é mais o que ela faz

14 variáveis

tudo do conjunto A, mais horas semanais, posição na ocupação, setor de atividade, grupo ocupacional e contribuição previdenciária

Mede o GAP RESIDUAL: duas pessoas no mesmo posto, com a mesma jornada e o mesmo vínculo, ganham igual?

A decomposição: por onde a diferença passa

33,1%

Gap total

Modelo do conjunto A, sem controlar ocupação. Toda a diferença associada ao sexo no mercado.

—

13,1%

Segregação ocupacional

A parcela que opera pela alocação em ocupações, setores e vínculos distintos.

=


20,0%

Gap residual

Modelo do conjunto B. O que sobra dentro do mesmo posto de trabalho, mesma jornada, mesmo vínculo.

Parte da diferença total opera pela alocação em ocupações, setores e vínculos distintos, e parte persiste dentro do mesmo posto de trabalho.

Fluxo do projeto



1

Carga e limpeza

Exclusão dos registros sem renda salarial declarada (VD4020 nulo ou zero) e restrição a pessoas de 16 anos ou mais;

2

EDA guiada por hipóteses

Elaboração de gráficos com intersecção de variáveis para verificação de padrão de renda conforme características das amostras;

3

Separação treino/teste

75/25 treino e teste com `random_state = 42`, antes de qualquer aprendizado — sem vazamento de dados;

4

Seleção de variáveis

Uso de variáveis explicativas: raça/cor, sexo, escolaridade, idade, ocupação e UF.
Variável alvo: renda e; peso amostral do governo;

5

Modelos + ajuste

imputação pela mediana e padronização das numéricas (idade e escolaridade) e One-Hot nas categóricas, tudo dentro de um Pipeline do scikit-learn;


6

Métricas e leitura

Uso da métrica MAE e análise do desempenho da variável alvo de renda.

O ponto de partida: renda mediana observada

Valores ponderados, população de 16 anos ou mais com rendimento do trabalho



Gap de 16,7% na mediana e de 22,9% na média entre homens e mulheres.

n por grupo: branca 16.613, parda 18.738, preta 4.212, amarela 278, indígena 214. Amarela e indígena têm poucos casos: leia com essa ressalva.

Os modelos - primeira rodada, em validação cruzada

Modelo	MAE (R\$)	RMSE (R\$)	R ²
Baseline (média do treino)	R\$ 2.001	R\$ 6.025	-0,000
Regressão Linear	R\$ 1.635	R\$ 5.560	0,189
Ridge (L2) e Lasso (L1)	R\$ 1.630	R\$ 5.560	0,189
Random Forest	R\$ 1.409	R\$ 5.621	0,160
Gradient Boosting	R\$ 1.441	R\$ 6.259	-0,300

Por que essa métrica?

Usamos o MAE porque o erro em reais é o que decide: quanto a previsão erra, em dinheiro. Esta tabela é a primeira rodada, em validação cruzada de 4 partes e sem ajuste fino — nenhum modelo aqui é o campeão. O campeão sai da etapa de ajuste, nos slides seguintes.

Limitações e ética

1

Base observacional

O modelo estima associações. Não estabelece relação causal. Não prova discriminação individual, não estabelece causalidade (os dados são observacionais) e não decide contratação, promoção ou concessão de crédito.

2

Seleção de quem entra

Só entra quem tem rendimento. Mulheres são maioria de quem ficou fora, então a desigualdade medida é uma subestimação.

3

Trabalho não remunerado

O trabalho de cuidado não aparece na base. Nunca dizer que mulheres trabalham menos.

4

Raça autodeclarada

É a declaração da pessoa na pesquisa, com todas as implicações disso. Sexo e raça entram para MEDIR a disparidade, nunca como critério de decisão; escolaridade e UF também podem operar como proxies e são monitoradas

5

Uma foto de um trimestre

3º trimestre de 2022, sem série temporal.

6

Grupos pequenos

Pessoas amarelas e indígenas têm poucos casos: sempre reportar o n ou não falar delas.

7

LGPD

Microdados públicos, anônimos e agregados da PNAD Contínua; nenhum registro identifica uma pessoa específica


8

Grupos pequenos

Os achados servem a políticas de equidade salarial (Lei 14.611/2023) e a auditorias de algoritmos, sempre com humano na decisão final

Como a renda está distribuída

Toda estatística descritiva é ponderada pelo peso amostral V1028



Mediana

R\$ 1.700

Média ponderada

R\$ 2.811, ou 1,65x a mediana

Gini

0,502

No salário mínimo

5.640 pessoas, 14,1% da base

Topo 1%

ganha 11,8x a mediana

A média fica bem acima da mediana: é uma distribuição puxada por poucos rendimentos muito altos.

A desigualdade não some com diploma, e ela se acumula

Mesmo nível, rendas diferentes

A mediana feminina é menor nos 7 níveis de escolaridade.

33,3%

de diferença no superior completo:
R\$ 4.500 para homens contra R\$
3.000 para mulheres

Escolaridade eleva a renda, com prêmio concentrado no ensino superior, mas não elimina a diferença dentro de cada nível.

Sexo e raça se somam

Do topo à base da tabela observada:

Homem branco

R\$ 2.300


Mulher negra

R\$ 1.220

47,0% de distância, ou R\$ 1.080 por mês e R\$ 12.960 por ano.

Como o campeão foi escolhido

Menor MAE em validação cruzada de 4 partes no treino, critério definido antes de ver os resultados



Campeão: GradientBoostingRegressor treinado no log da renda, conjunto B, learning rate 0,04, 800 árvores, profundidade 5, folha mínima 50, subsample 0,7. As previsões saem em reais.

O conjunto de teste foi aberto uma única vez, no fim, só para o campeão.

O campeão no teste — conjunto aberto uma única vez

Régua	MAE	RMSE	R2	Erro % mediano
Chute da média	R\$ 1.957	R\$ 3.828	-0,0	77,0%
Chute da mediana, o piso a bater	R\$ 1.644	R\$ 3.986	-0,1	40,0%
Campeão	R\$ 1.166	R\$ 3.049	0,366	30,6%

29,1% menos erro que o piso

Resíduo médio de R\$ 453. O conjunto B reduz o erro em 13,3% frente ao A.

R² de 0,366 é honesto

Faltam experiência efetiva, tempo de casa, tamanho da empresa e área de formação. Isso é limite da base, não defeito do modelo.

Auditoria de erro por grupo: MAE de R\$ 1.329,8 para homens e R\$ 938,2 para mulheres, com viés médio de mesmo sinal e mesma ordem de grandeza.

O que mais pesa para prever renda

Importância por permutação, medida no teste, em reais de piora do MAE



Cuidado com a leitura

Peso baixo de sexo e raça não significa desigualdade pequena. Significa que, para prever renda, ocupação e jornada carregam mais informação.

Quem responde à pergunta do TCC não é a importância: é o contrafactual.

Resultado

20,0%

corresponde à mediana das diferenças individuais calculadas para as mesmas 10.016 pessoas avaliadas, alterando-se apenas a variável sexo e mantendo-se constantes todas as demais variáveis.

R\$ 1.782

prevista como homem

R\$ 1.467

prevista como mulher

99,6%

dos perfis: o homem ganha mais


R\$ 4.042

a menos por ano

Há duas formas de resumir o mesmo experimento: a diferença entre as duas medianas é de 17,7% e a mediana das diferenças individuais é de 20,0%. O número principal do trabalho é 20,0%.

Renda mediana prevista por gênero e raça

Mesmo conjunto de teste, variando sexo e raça dos perfis



O achado robusto

Todos os perfis femininos ficam abaixo de todos os masculinos. Mediana feminina R\$ 1.429 contra R\$ 1.738, separação de 17,8%.

O que não afirmamos

A ordem fina entre raças não é confiável nos grupos pequenos: homem amarela $n = 95$, homem indígena $n = 97$, mulher amarela $n = 106$ e mulher indígena $n = 62$.


Quatro pessoas idênticas, exceto em sexo e raça

35 anos, superior completo, São Paulo, mesma ocupação e mesma jornada




Homem branco

R\$ 2.765




Homem preto

R\$ 2.564



Mulher branca

R\$ 2.057



Mulher preta

R\$ 1.947

Da maior para a menor: R\$ 818 por mês, 29,6% de diferença, R\$ 9.811 por ano.

Do modelo à tela: a Régua da Renda

O achado do trabalho traduzido para quem não abre um notebook

1

O que é

Uma página aberta que mostra as previsões do modelo para perfis equiparados e deixa qualquer pessoa montar e comparar dois perfis.

2

O que não faz

Não pede dado pessoal, não avalia pessoas reais e não decide salário, contratação nem crédito. Toda tela avisa que é protótipo acadêmico.

Acesse agora



anaglebia.github.io/We-can-fly

A comparação interativa não executa o modelo treinado: é uma aproximação calibrada sobre as previsões reais do slide anterior. A distinção está escrita na própria página.

Da medida à ação: o Auditor de Paridade

A mesma régua do TCC aplicada à folha de pagamento de uma empresa

1

O que é

Recebe uma folha de pagamento e mostra onde está a diferença salarial por cargo, quanto custa corrigir e como ela se compara ao mercado brasileiro.

2

Por que importa

A Lei 14.611/2023 exige igualdade de remuneração para trabalho de igual valor e plano de ação onde houver desigualdade. A ferramenta entrega medir, priorizar e precificar.

Acesse agora



anaglebia.github.io/We-can-fly/auditor.html

Conclusões e próximos passos

Achados da análise:

- A igualdade na mediana não é igualdade: é o efeito do piso legal do salário mínimo, que atinge homens e mulheres da mesma forma. A desigualdade de gênero aparece acima do piso, e cresce conforme a renda sobe;
- O grupo (Homem · branco) tem renda mediana 47,0% maior que o grupo na base (Mulher · negra (preta ou parda));
- TODOS os perfis femininos ficam abaixo de TODOS os masculinos;
- As diferenças por sexo e raça persistem mesmo controlando escolaridade, idade e UF;
- Perfis equivalentes, rendas diferentes.

Posterior ao nosso estudo:

- Tratar as pendências da base: as 5 linhas duplicadas e as 44 jornadas acima de 98 horas por semana, e traduzir o código 11 de grupo_ocupacional;
- Ampliar a janela temporal, repetindo o mesmo desenho em vários trimestres, para ver se o gap residual sobe, cai ou fica parado;
- Enfrentar a seleção amostral, modelando quem ficou fora da população com rendimento, para não subestimar a desigualdade;
- Testar o protótipo com o público para quem ele foi desenhado e ajustar linguagem e telas a partir do retorno;
- Incorporar o desenho amostral complexo da PNAD nos testes de significância;
- Incorporar fontes que contemplem a população LGBTQIA+, hoje invisível nas estatísticas oficiais.

IMPORTANTE

O modelo descreve a desigualdade que existe nos dados, ele não a justifica.

“Dados não mudam a realidade sozinhos — mas mostram exatamente onde ela precisa mudar.”

Usá-lo para definir salário seria automatizar a desigualdade que ele foi feito para denunciar.

Mantidas constantes as variáveis observáveis do modelo, estima-se uma diferença de 20,0% na renda do trabalho associada ao sexo, na PNAD Contínua de 2022.